

Statistique Descriptive Bivariée

Partie 2: "Régression"

Pr. A. Abbassi, Pr. L. A. Allamy, Pr. M. Louriki

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

29 septembre 2025

Remarque

Dans cette partie du chapitre 2, on ne considèrera que les variables statistiques quantitatives.

Exemple

$(X, Y) = (\text{taille (en cm)}, \text{poids (en kg)})$

X	155	163	170	178	185
Y	47	61	54	70	73

Coefficient de corrélation

Considérons deux variables statistiques quantitatives X et Y . Souvent, on se pose la question d'existence d'un lien, d'une relation entre X et Y et éventuellement l'exprimer mathématiquement.

Nuage de points

Soient $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, n observations du couple (X, Y) (un n -échantillon de (X, Y)).

Ces couples peuvent être représentés dans un plan orthogonal (x_i en abscisse et y_i en ordonnée) et donnent alors naissance à ce qu'on appelle "un nuage de points".

Définition

On mesure le lien de dépendance linéaire entre deux variables quantitatives X et Y par le coefficient de corrélation, noté r_{XY} , défini par :

$$r_{XY} = \frac{s_{XY}}{s_X s_Y}$$

où $s_{XY} = \frac{1}{n} \sum_i x_i y_i - \bar{x} \bar{y}$ et $s_X^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2$.

On rappelle que $\bar{x} = \frac{1}{n} \sum_i x_i$, $\bar{y} = \frac{1}{n} \sum_i y_i$


Remarque

- $r_{XY} \in [-1, 1]$
- $|r_{XY}| = 1 \Leftrightarrow$ dépendance linéaire parfaite entre X et Y .

Exemple-suite

- La taille moyenne est : $\bar{x} = 170,2$ cm.
- Le poids moyen est : $\bar{y} = 61$ kg.
- $s_{XY} = \left(\frac{52373}{5}\right) - \bar{x}\bar{y} = 92,4$.
- $s_X^2 = \frac{1}{5}(145403) - (\bar{x})^2 = 112,56 \rightarrow s_X = 10,6094$.
- $s_Y^2 = \frac{1}{5}(19075) - (\bar{y})^2 = 94 \rightarrow s_Y = 9,695359$.
- $r_{XY} = \frac{92.4}{\sqrt{94 \times 112.56}} = 0.89829 \Rightarrow$ il y a une forte liaison linéaire entre la taille et le poids.

Représentation d'un nuage de points



Droite de régression

En régression linéaire, on cherche à déterminer une droite qui ajuste le mieux possible le nuage.

On utilise la méthode des moindres carrés.

Cette méthode consiste à trouver la droite (D) : $y = ax + b$ qui approche le mieux le nuage, au sens des moindres carrés. Ceci revient à minimiser la somme des carrés des écarts entre :

- y_i (ordonnée de x_i dans le nuage) et
- $ax_i + b$ (ordonnée de x_i sur la droite).

Droite de régression

On cherche alors à minimiser : $\sum_{i=1}^n (y_i - (ax_i + b))^2$

On obtient alors ce minimum pour :

$$\hat{a} = \frac{s_{XY}}{s_X^2} \text{ et } \hat{b} = \bar{y} - \hat{a}\bar{x}$$

$$\text{où } \bar{x} = \frac{1}{n} \sum_i x_i, \bar{y} = \frac{1}{n} \sum_i y_i, s_{XY} = \frac{1}{n} \sum_i x_i y_i - \bar{x}\bar{y} \text{ et}$$

$$s_X^2 = \frac{1}{n} \sum_i x_i^2 - \bar{x}^2$$

Equation de la droite de régression

L'équation de la droite de régression est donnée par :

$$(D) : y = \hat{a}x + \hat{b}$$

$$\text{où } \hat{a} = \frac{s_{XY}}{s_X^2} \text{ et } \hat{b} = \bar{y} - \hat{a}\bar{x}$$

Remarque

- La droite de régression passe par le point $(\bar{x}, \bar{y})$.
- Elle donne un modèle de prédiction. On peut prédire des valeurs qui ne figurent pas dans le tableau, à partir de l'équation de la droite.

Relation entre les coefficients

On a la relation suivante, entre $\hat{a}$ et r_{XY} :

$$\hat{a} = r_{XY} \times \frac{s_Y}{s_X}$$

$$\text{en effet : } \hat{a} = \frac{s_{XY}}{s_X^2} = \frac{s_{XY}}{s_X \times \textcolor{red}{s_Y}} \times \frac{\textcolor{red}{s_Y}}{s_X} = r_{XY} \times \frac{s_Y}{s_X}$$

Exemple-suite

Exemple-suite

- La taille moyenne est : $\bar{x} = 170,2$ cm.
- Le poids moyen est : $\bar{y} = 61$ kg.
- $s_{XY} = \left(\frac{52373}{5}\right) - \bar{x}\bar{y} = 92,4$.
- $s_X^2 = \frac{1}{5}(145403) - (\bar{x})^2 = 112,56 \rightarrow s_X = 10,6094$.
- $s_Y^2 = \frac{1}{5}(19075) - (\bar{y})^2 = 94 \rightarrow s_Y = 9,695359$.
- $\hat{a} = \frac{s_{XY}}{s_X^2} \simeq 0,82089$.
- $\hat{b} = \bar{y} - \hat{a}\bar{x} \simeq -78,7$.

Exemple-suite

L'équation de la droite de régression est : $y = 0,821x - 78,7$

→ On voudrait prédire le poids d'une personne ayant une taille de 1,80 m :

$$y = 0,821 \times 180 - 78,7 = 69,08$$

Le poids recherché est presque égal à 69 kg.

Représentation du nuage de points





Figure 2 – Nuage de points taille-poids

Tracé du nuage de points et de la droite de régression



Résidus ou erreurs de prédiction

Les **résidus de la régression linéaire** sont définis par :

$$e_i = y_i - (\hat{a}x_i + \hat{b}) = y_i - y_i^*; \quad i = 1, \dots, n$$

- Le résidu e_i est l'erreur que l'on commet en utilisant la droite de régression linéaire pour prédire y_i à partir de x_i .
- Les résidus sont les différences entre les valeurs observées y_i et les valeurs ajustées y_i^* ; $i = 1, \dots, n$.

- Moyenne résiduelle : $\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i = \frac{1}{n} \sum_{i=1}^n (y_i - (\hat{a}x_i + \hat{b}))$

- Variance résiduelle : $s_e^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 - (\bar{e})^2$

Remarques

- On a toujours $\sum_{i=1}^n e_i = 0$.
- La variance résiduelle s'écrit alors :
$$s_e^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 = s_Y^2 [1 - r_{XY}^2].$$
- La variance résiduelle est la variance non expliquée par la droite de régression de Y en X .

Fin de la partie 2 du Chapitre 2
BON COURAGE