

Statistique Descriptive Univariée

"Partie 2"

Pr. A. Abbassi, Pr. L. A. Allamy, Pr. M. Louriki

Université Cadi Ayyad
Faculté des Sciences Semlalia Marrakech

24 novembre 2025

Statistique Descriptive Univariée

“Partie 2”

Histogramme (variable quantitative continue)

Définition

L'histogramme est utilisé pour représenter une **variable quantitative continue**, dont les valeurs sont regroupées en classes.

- L'intervalle des valeurs est divisé en K classes : $\{[e_i, e_{i+1}[, i = 1, \dots, K\}$.
- Chaque classe est représentée par un **rectangle**, **juxtaposé ou contigu** aux autres classes.
- La largeur du rectangle est **proportionnelle à l'amplitude de la classe**.
- La surface du rectangle (et non la hauteur seule) est proportionnelle :
 - aux effectifs (histogramme des effectifs), ou
 - aux fréquences (histogramme des fréquences).

Remarques sur l'histogramme

À retenir

- L'amplitude de la classe i est $a_i = e_{i+1} - e_i$.
- Si toutes les classes ont la **même amplitude**, on peut placer en ordonnée directement les effectifs (n_i) ou les fréquences (f_i).
- Si les classes ont des **amplitudes différentes**, on place en ordonnée les **hauteurs normalisées** : $\frac{n_i}{a_i}$ ou $\frac{f_i}{a_i}$.
- Les rectangles sont **contigus** pour montrer la continuité de la variable.

Variable Statistique quantitative


On considère la série statistique ordonnée, de valeurs brutes, relative aux âges des 50 membres d'un club sportif :

17	18	19	20	22	22	23	23	24	25
25	26	26	27	27	27	27	27	28	28
28	28	28	29	29	29	29	30	30	30
30	30	31	31	31	31	31	32	32	33
33	34	35	35	36	36	38	39	40	41

Dans un premier temps, on regroupe ces données en cinq classes de même amplitude, dont la borne inférieure de la 1^{ère} classe est 15 et la borne supérieure de la dernière classe est 45. On obtient les résultats suivants :

Classes d'âge	a_i	C_i	n_i	f_i	Haut. $h_i = \frac{n_i}{a_i}$	Haut. $d_i = \frac{f_i}{a_i}$
[15; 21[	6	18	4	0.08	4/6	0.08/6
[21; 27[	6	24	9	0.18	9/6	0.18/6
[27; 33[	6	30	26	0.52	26/6	0.52/6
[33; 39[	6	36	8	0.16	8/6	0.16/6
[39; 45[	6	42	3	0.06	3/6	0.06/6
Total			50	1		


Histogramme des âges avec amplitudes égales



Dans un second temps, on regroupe ces données en six classes d'**amplitudes différentes**, [15; 18[, [18; 21[, [21; 25[, [25; 30[, [30; 35[et [35; 45[.

On obtient les résultats suivants :

Classes d'âge	a'_i	C'_i	n'_i	f'_i	Haut. $h'_i = \frac{n'_i}{a'_i}$	Haut. $d'_i = \frac{f'_i}{a'_i}$
[15; 18[	3	16.5	1	0.02		
[18; 21[	3	19.5	3	0.06		
[21; 25[	4	23	5	0.1		
[25; 30[	5	27.5	18	0.36		
[30; 35[	5	32.5	15	0.3		
[35; 45[	10	40	8	0.16		
Total			50	1		



Histogramme avec amplitudes différentes

Paramètres statistiques

Paramètres de position ou caractéristique de valeur centrale ou tendance centrale

La moyenne arithmétique :

Définition

On appelle "moyenne arithmétique", notée $\bar{x}$, de la série statistique $x_1, x_2, \dots, x_n$, où n est la taille de l'échantillon, la quantité :

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n) = \frac{1}{n} \sum_{i=1}^n x_i.$$

Calcul de la moyenne arithmétique

- (a) Sur la série **brute**, le calcul de la moyenne se fait selon la définition ci-dessus.
- (b) Si la série est présentée sous forme d'une série à **valeurs isolées** (x_j, n_j) ; $j = 1, \dots, J$ (J étant le nombre de valeurs différentes de la série), alors :

$$\bar{x} = \frac{1}{n} \sum_{j=1}^J n_j x_j = \sum_{j=1}^J f_j x_j$$

C'est une moyenne pondérée $\left(x_j, f_j = \frac{n_j}{n}\right)_{j=1, \dots, J}$

Calcul de la moyenne arithmétique

- (c) Si la série est présentée sous forme d'une série à **valeurs classées** $([e_i, e_{i+1}[; n_i)$ $i = 1, \dots, K$, K étant le nombre de classes, nous pouvons effectuer l'**approximation** consistant à prendre comme représentant de la $i^{\text{ème}}$ classe son centre (son milieu) C_i :

$$\bar{x} = \bar{C} = \frac{1}{n} \sum_{i=1}^K n_i C_i = \sum_{i=1}^K f_i C_i,$$

$$\text{où } C_i = \frac{e_i + e_{i+1}}{2}, \quad i = 1, \dots, K.$$

Remarque sur la moyenne arithmétique

Avantages et inconvénients

La moyenne arithmétique est facile à calculer, mais elle est sensible aux valeurs extrêmes. Si certaines valeurs de la série sont très petites ou très grandes par rapport aux autres, la moyenne peut être fortement influencée et ne pas refléter correctement la tendance générale.

Exemple

Si on considère la série de nombres : 1, 5, 7, 4, 3, la moyenne est $\bar{x} = 4$.

Si maintenant, on remplace 3 par 13, la moyenne devient alors $\bar{x} = 6$.

Les modes


Objectif : On veut déterminer les points en lesquels la courbe des fréquences présente un maximum relatif, au sens large.

Série à **valeurs isolées** $(x_j; n_j); j = 1, \dots, J$

Définition

On appelle **mode** de la série, tout élément de la suite **ordonnée** des x_j , dont la fréquence est non-inférieure aux fréquences des deux éléments voisins.

Cas de série bimodale



Cette série admet deux modes : $\text{mode1} = x_3$ et $\text{mode2} = x_6$.

Les modes

Série à **valeurs classées** $([e_i; e_{i+1}[; n_i)_{i=1,\dots,K}$

Définition

On appelle classe modale toute classe dont la hauteur est non-inférieure aux hauteurs des classes voisines. On prend pour mode le centre (ou milieu) de la classe modale considérée.

Remarques

- Une série statistique peut avoir un ou plusieurs modes.
- Une série à un mode est une série "unimodale".
- Une série à deux modes est une série "bimodale".
- Une série à trois modes est une série "trimodale".
- Une série à plusieurs modes est une série "multimodale".

Remarques : Avantages et inconvénients des modes

- Dans le cas d'une série à valeurs classées, un mode varie suivant le choix des classes.
- Un mode a une signification concrète et sa détermination est simple.
- Le mode n'est pas toujours bien défini dans le cas d'une variable continue.

Objectif : On veut déterminer un nombre tel que 50% des éléments de la série soient inférieurs à ce nombre et 50% lui soient supérieurs.

Définition

La médiane, notée M ou $x_{1/2}$, est la valeur centrale de la série statistique qui partage la série en deux groupes de même effectif.

La médiane

a) Si la série est à **valeurs isolées**, on ordonne les éléments de la série par ordre croissant, sans regrouper les éléments égaux. On obtient :

$$x_{(1)} \leq x_{(2)} \leq x_{(3)} \leq \dots \leq x_{(n)}.$$

Si $n = 2p + 1$ (impair), la médiane $M = x_{1/2} = x_{(p+1)}$.

Si $n = 2p$ (pair), la médiane $M = x_{1/2} = \frac{x_{(p)} + x_{(p+1)}}{2}$.

Avant de parler du cas continu, on définit l'effectif cumulé et la fréquence cumulée.

- (i) On appellera **effectif cumulé** correspondant à la $i^{\text{ème}}$ valeur d'une série statistique le nombre :

$$N_i = \sum_{k=1}^i n_k$$

- (ii) On appellera **fréquence cumulée** correspondant à la $i^{\text{ème}}$ valeur d'une série statistique le nombre :

$$F_i = \sum_{k=1}^i f_k = \sum_{k=1}^i \frac{n_k}{n}$$

b) Si la série est à **valeurs classées**, on peut déterminer une **valeur approchée** de la **médiane** de la manière suivante :

On cherche l'intervalle $[N_i, N_{i+1}[$ d'effectifs cumulés (resp. $[F_i, F_{i+1}[$ de fréquences cumulées) auquel appartient $n/2$ (resp. $1/2$).

On repère alors la classe $[e_i, e_{i+1}[$ correspondante puis on détermine une valeur approchée de la médiane par interpolation linéaire à l'intérieur de cette classe.

$$M = x_{1/2} \simeq e_i + (e_{i+1} - e_i) \frac{n/2 - N_i}{N_{i+1} - N_i} = e_i + (e_{i+1} - e_i) \frac{n/2 - N_i}{n_{i+1}},$$

respectivement

$$M = x_{1/2} \simeq e_i + (e_{i+1} - e_i) \frac{1/2 - F_i}{F_{i+1} - F_i} \simeq e_i + (e_{i+1} - e_i) \frac{1/2 - F_i}{f_{i+1}}.$$

Exemple

Supposons une série de notes regroupées en classes :

Classe	$[0, 4[$	$[4, 8[$	$[8, 12[$	$[12, 16[$
Effectif n_i	3	7	10	5

Effectifs cumulés : $N_i = 3, 10, 20, 25$. La classe médiane contient $n/2 = 12,5$, donc $[8, 12[$.

Interpolation : $M \simeq 8 + (12 - 8) \frac{12,5 - 10}{10} = 8 + 2,5 = 10,5$.

Remarque

La médiane est moins sensible aux valeurs extrêmes que la moyenne.

Exemple

En reprenant les deux séries de l'exemple ci-dessus, on remarque que la médiane est $M = 7$ dans les deux cas alors que la moyenne était très affectée par la valeur extrême.

Les quartiles

Objectif : On veut déterminer trois nombres Q_1 , Q_2 et Q_3 tels que :

- 25% des éléments de la série soient **inférieurs** à Q_1
- 25% des éléments de la série soient **entre** Q_1 et Q_2
- 25% des éléments de la série soient **entre** Q_2 et Q_3
- 25% des éléments de la série soient **supérieurs** à Q_3 .

Remarques

- Q_2 n'est autre que la médiane.
- La détermination des quartiles est semblable à celle de la médiane.

Détermination de Q_1 (série discrète)

Méthode

Soit $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ une série **ordonnée** (indices entre parenthèses), où n est la taille de l'échantillon. Le premier quartile Q_1 est défini de la manière suivante :

$$\begin{cases} Q_1 = \frac{x_{(\frac{n}{4})} + x_{(\frac{n}{4}+1)}}{2}, & \text{si } \frac{n}{4} \in \mathbb{N}, \\ Q_1 = x_{(\text{entier le plus proche de } \frac{n}{4} + 0,5)}, & \text{si } \frac{n}{4} \notin \mathbb{N}. \end{cases}$$

Autrement dit, si $\frac{n}{4}$ est un entier, on fait la moyenne des deux valeurs centrales, sinon on prend la valeur correspondant à l'indice entier le plus proche de $\frac{n}{4} + 0,5$.

Détermination de Q_1 (série discrète)

Exemple

- Pour $n = 12$, on a $\frac{n}{4} = 3$.

$$\Rightarrow Q_1 = \frac{x_{(3)} + x_{(4)}}{2}.$$

- Pour $n = 13$, on a $\frac{n}{4} = 3,25$.

L'entier le plus proche de $3,25 + 0,5 = 3,75$ est 4.

$$\Rightarrow Q_1 = x_{(4)}.$$

Détermination de Q_3 (série discrète)

Méthode

De la même façon, le troisième quartile Q_3 est défini par :

$$\begin{cases} Q_3 = \frac{x_{(\frac{3n}{4})} + x_{(\frac{3n}{4}+1)}}{2}, & \text{si } \frac{3n}{4} \in \mathbb{N}, \\ Q_3 = x_{(\text{entier le plus proche de } \frac{3n}{4}+0,5)}, & \text{si } \frac{3n}{4} \notin \mathbb{N}. \end{cases}$$

Détermination de Q_3 (série discrète)

Exemple

- Pour $n = 12$, $\frac{3n}{4} = 9$.

$$\Rightarrow Q_3 = \frac{x_{(9)} + x_{(10)}}{2}.$$

- Pour $n = 13$, $\frac{3n}{4} = 9,75$.

L'entier le plus proche de $9,75 + 0,5 = 10,25$ est 10.

$$\Rightarrow Q_3 = x_{(10)}.$$

Détermination de Q_1 (série à valeurs classées)

Méthode : On cherche l'intervalle $[N_i, N_{i+1}[$ d'effectifs cumulés (resp. $[F_i, F_{i+1}[$ de fréquences cumulées) auquel appartient $\frac{n}{4}$ (resp. $\frac{1}{4}$).

On repère alors la classe $[e_i, e_{i+1}[$ correspondante puis on détermine une valeur approchée du premier quartile par interpolation linéaire :

$$Q_1 \simeq e_i + (e_{i+1} - e_i) \frac{\frac{n}{4} - N_i}{N_{i+1} - N_i} = e_i + (e_{i+1} - e_i) \frac{\frac{n}{4} - N_i}{n_{i+1}},$$

respectivement

$$Q_1 \simeq e_i + (e_{i+1} - e_i) \frac{\frac{1}{4} - F_i}{F_{i+1} - F_i} = e_i + (e_{i+1} - e_i) \frac{\frac{1}{4} - F_i}{f_{i+1}}.$$

Détermination de Q_3 (série à valeurs classées)

Méthode : On cherche l'intervalle $[N_i, N_{i+1}[$ d'effectifs cumulés (resp. $[F_i, F_{i+1}[$ de fréquences cumulées) auquel appartient $\frac{3n}{4}$ (resp. $\frac{3}{4}$).

On repère alors la classe $[e_i, e_{i+1}[$ correspondante puis on détermine une valeur approchée du premier quartile par interpolation linéaire :

$$Q_3 \simeq e_i + (e_{i+1} - e_i) \frac{\frac{3n}{4} - N_i}{N_{i+1} - N_i} = e_i + (e_{i+1} - e_i) \frac{\frac{3n}{4} - N_i}{n_{i+1}},$$

respectivement

$$Q_3 \simeq e_i + (e_{i+1} - e_i) \frac{\frac{3}{4} - F_i}{F_{i+1} - F_i} = e_i + (e_{i+1} - e_i) \frac{\frac{3}{4} - F_i}{f_{i+1}}.$$

Le diagramme en boîte ou box-plot ou boîte à moustaches

C'est un diagramme qui permet de représenter les quartiles, les valeurs extrêmes et les valeurs aberrantes éventuelles (ou erreurs de mesure). Il se présente comme un rectangle de largeur $Q_3 - Q_1$, prolongé par des "moustaches" de part et d'autre de longueur au plus égale à $1.5(Q_3 - Q_1)$

Remarques

- L'écart interquartile : $IQ = Q_3 - Q_1$.
- Les valeurs atypiques sont appelées aussi les valeurs aberrantes.
- La frontière basse Fb est définie par :
$$Fb = Q_1 - 1.5 \times (Q_3 - Q_1) = Q_1 - 1.5(IQ).$$
- L'extrémité gauche de la moustache est définie par :
$$b^- = \text{Inf} \{x_i / x_i \geq Fb\}.$$
- La frontière haute Fh est définie par :
$$Fh = Q_3 + 1.5 \times (Q_3 - Q_1) = Q_3 + 1.5(IQ).$$
- L'extrémité droite de la moustache est définie par :
$$b^+ = \text{Sup} \{x_i / x_i \leq Fh\}.$$




Figure 3 – Le diagramme en boîte.

Définition

Les valeurs aberrantes sont des observations qui s'écartent nettement du reste des données. Elles peuvent être :

- **Supérieures à la normale** : beaucoup plus grandes que la majorité des valeurs de la série.
- **Inférieures à la normale** : beaucoup plus petites que la majorité des valeurs de la série.

Dans le contexte du box-plot

- On calcule les quartiles Q_1 et Q_3 .
- Frontière basse : $Fb = Q_1 - 1.5 \times (Q_3 - Q_1)$
- Frontière haute : $Fh = Q_3 + 1.5 \times (Q_3 - Q_1)$
- Toute valeur inférieure à Fb ou supérieure à Fh est considérée comme aberrante.

Paramètres de dispersion

L'étendue :

Définition :

Pour une série à valeurs isolées, **ordonnée**, l'étendue E est la différence entre la plus grande et la plus petite des valeurs de la série :

$$E = x_{(n)} - x_{(1)}.$$

L'écart interquartile :

Définition

L'écart interquartile n'est rien d'autre que $IQ = Q_3 - Q_1$, la différence entre le 3^{ème} et le 1^{er} quartile.

La variance et l'écart-type

Ils mesurent la dispersion autour de la moyenne.

Définition

La variance d'une série est donnée par la formule suivante :

$$\begin{aligned}s^2 = \text{Variance} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{j=1}^J n_j (x_j - \bar{x})^2 \\ &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{j=1}^J n_j x_j^2 - \bar{x}^2,\end{aligned}$$

$$s = \text{Ecart-type} = \sqrt{\text{Variance}}.$$

Remarque

Dans le cas d'une variable classée, la variance s'écrit :

$$s^2 = \text{Variance} = \frac{1}{n} \sum_{j=1}^K n_j (C_j - \bar{x})^2 = \frac{1}{n} \sum_{j=1}^K n_j C_j^2 - \bar{x}^2$$

Fin de la partie 2 du chapitre
Statistique Descriptive Univariée
BON COURAGE
BONNE COMPREHENSION